

附件 4

2026 年安徽省 AI 大模型创新应用竞赛

作品赛赛道

作品名称：知行（ZHIXING AGENT）

2026 年 9 月

填写说明

1. 所有参赛作品必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛作品（或方案）。
2. 作品报告采用 A4 纸撰写。除标题外，所有内容必需为宋体、五号字、1.5 倍行距。
3. 作品报告中各作品模板文字部分仅供参考，作品报告书撰写完毕后，请删除所有模板文字。（本页不删除）
4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。
5. 网评采用双盲评审，因此请勿在该文档出现任何有关学校、队伍、个人等信息，否则按作弊论处。
6. 报告正文不超过 10 页。
7. 作品最终以 PDF 格式提交。

作品简介

作品名称	知行 (ZHIXING AGENT)
主题	
作品简介	知行是一套面向个人用户的多模态 Web 智能助理。用户可以通过浏览器输入文字、上传图片、语音和文件，把生活、学习与工作中的复杂任务交给知行处理。系统以 ReAct Agent 为核心，结合可配置 Skill、多类 Tool、长期记忆、目标跟进和主动通知能力，完成信息检索、天气与出行查询、旅行规划、校园课表、文件处理、图像理解、语音转写和内容生成等任务。项目采用 React 18 + TypeScript 前端与 Spring Boot 3.3 + Java 21 后端，接入 Qwen/DashScope 文本、视觉、ASR、TTS、图像模型，并以 SQLite 保存业务状态、以 Qdrant 支撑向量记忆和 Skill 知识检索。系统通过 SSE 实现对话流式输出和用户级通知推送，通过 app_user.id 实现多用户数据隔离。
作品来源	面向个人事务管理与多模态交互需求设计开发的 Web 智能助理应用。
应用行业	个人效率工具、校园生活服务、日常出行与信息管理等。
数据来源	用户主动提交的对话与附件；公开信息接口；Skill 配置与领域知识；模型生成及向量化结果。
作品展示	浏览器端 Web 程序；支持文本、图片、音频与文件交互。

一 选题定位与社会价值

知行是一款面向个人学习、工作和生活事务的 Web 智能助理，以“会记忆、会执行、会主动跟进”为产品主线。用户通过浏览器表达目标，系统将自然语言、多模态附件、领域工具和持久化状态连接起来，提供从问题理解、信息补全、实际执行到结果呈现的连续服务。

1 需求与问题

个人事务往往跨越多个应用：安排出行需要天气、地点和路线信息，管理课程需要解析文件并配置提醒，长期目标需要多次记录和复盘。仅获得一段建议并不能完成这些事务，用户仍需手动切换工具、补充背景并记住后续行动。知行将这些步骤集中到对话工作台，减少重复表达和信息搬运。

2 目标用户与场景

面向学生，知行提供课表与考试资料导入、查询和提醒；面向日常出行用户，提供天气、地点、交通与旅行方案相关工具；面向有资料处理需求的用户，提供附件解析和文件生成；面向需要长期跟进的用户，提供目标、定时任务和信息订阅。各场景使用同一账户对话记录和操作轨迹，降低重复学习成本。

3 预期价值与推广条件

作品的价值在于把模型理解与真实业务操作结合，让执行结果、生成文件和后续通知回到同一工作台。记忆管理页面支持用户查看个人记忆，工具轨迹和确认卡片使执行过程更易理解。可配置 Skill 支持领域扩展，Web 形态便于在具备浏览器的终端使用。

当前形态适合个人和小规模应用验证。进一步推广需要稳定的模型与业务接口、通知渠道配置和运维保障；效率提升、用户满意度和成本节约应通过后续真实用户试用量化，不预设未经测量的收益。

二 系统架构与模型分工

知行采用 React 18 与 TypeScript 前端、Java 21 与 Spring Boot 3.3 后端。Vite 构建产物由后端静态目录托管，形成一个 Web 应用。下图按职责展示模块依赖，并非将模块拆分为独立微服务。




图 1 知行技术架构。聊天与定时任务共享业务能力；通知服务写入 outbox 后调用用户级 SSE 推送。模型、向量检索及第三方信息接口属于外部依赖。

1 模型负责理解与生成

配置模板将文本模型设为 qwen3.6-plus，视觉模型为 qwen-vl-max，图像模型为 qwen-image-2.0，ASR 为 paraformer-v2，TTS 为 cosyvoice-v3-flash。文本模型通过兼容接口返回正文或结构化工具调用，业务代码负责实际执行。以上为代码配置示例，部署时可调整，不代表各外部服务均已完成在线验证。

2 存储负责状态与结果

SQLite 保存账户、可见消息、模型上下文、运行状态和业务数据；Qdrant 支撑长期记忆与 Skill 知识检索；ArtifactService 管理上传件与生成产物。长期记忆的 Embedding 示例配置使用 BGE-M3、1024 维；向量模型与知识集合维度需要保持一致。

三 从输入到执行的核心流程

WebChatController 从认证会话取得用户身份，解析或创建所属对话，并建立 runId。ChatApplicationService 解析附件、创建请求级产物收集器，再将消息与身份交给 ReActAgentExecutor。




图2 内联 ReAct 主执行流程。专用 Skill 执行器可承接独立工作流；已有待确认交互也可在进入普通循环前处理。工具结果回到模型，构成后续判断依据。

SkillRouter 按显式切换、待处理交互、强规则触发、续接判断及语义路由选择能力。ExecutionLoop 默认限制最多 15 轮、累计 32 次工具调用，并处理空回复、结构化计划校验和终止汇总。SafetyPolicy 默认对 file_delete 与 file_update 要求确认；用户可确认或取消，不将所有工具都描述为强制确认。

四 提示词与多模态上下文设计

1 分层提示词与能力约束

提示词由系统规则、所选 Skill 的场景说明、工具定义和相关知识共同构成。系统规则说明角色与执行要求；Skill 提示词强调旅行、校园、天气等场景的处理步骤；工具定义为模型提供名称、参数与用途。SystemPromptBuilder 注入 Skill 检索知识，避免在上下文组装阶段重复召回。

例如“根据这份课表安排提醒”先需要附件解析，再识别课程信息和缺失条件，最后调用相应业务工具。可靠完成的依据应是工具结果与业务状态，而非模型单纯回复“已经设置”。项目的 SkillReplyGuard 机制及相关测试针对提醒、目标等场景约束结束回复。

2 历史摘要与长期记忆

DefaultContextBuilder 组合最近对话轮次、当前消息与长期记忆，并支持摘要和按轮次边界的预算裁剪。当前 ReActAgentExecutor 构造时将预算参数传为 0，即该入口尚未启用固定 token 预算裁剪；不能将“具备预算组件”写成“已全面启用动态压缩”。

对于“记住……”类明确请求，ChatApplicationService 还提供异步保存路径：匹配短文本后调用 saveManual。该路径降低了对模型主动调用记忆工具的依赖，但仍可能因存储或外部依赖异常失败，因此不承诺记忆绝对不会丢失。长期记忆与会话摘要分别服务于跨轮偏好和历史压缩，职责不同。

3 附件输入与产物输出

附件先校验用户归属，再按类型处理：图片转为视觉请求，音频转写为文本，文件交由解析服务提取内容。提取结果以附件标识拼接到输入消息；上传处理去重并最多取 8 件附件。文档解析依赖 Tika、PDFBox 和 POI 等组件，与调用视觉模型属于不同处理路径。

生成图片、语音或文件通过请求级 ArtifactCollector 汇入当轮响应，由前端展示或下载。知行同时提供角色管理界面及音色相关配置；角色界面与声音样本上传的存在，不等于所有自定义声音已具备可用的在线合成能力。

五 工程特点与技术问题

1 规则与模型联合路由

作品的应用创新在于将可解释的规则触发、会话续接和模型语义路由组合起来，再通过可配置 Skill 限定任务能力。明确切换和待处理交互具有优先级，可以减少多轮任务中错误继承旧场景的问题。此创新属于应用编排与工程实现，不宣称提出新的基础模型算法。

2 可见记录与模型上下文解耦

chat_messages 和 chat_runs 保存用户可见正文、附件、工具轨迹、产物及状态；context_messages 服务于模型上下文。两者分离，使界面记录不必完全依赖于推理的历史格式。启动迁移会将未完成的 STREAMING 运行标记为 FAILED，并保留中断前内容；这属于结果保留和失败恢复，不等同于自动续跑所有任务。

3 身份传递与操作确认

Spring Security 使用会话认证、CSRF 和 BCrypt。用户身份传递到会话、记忆、附件和通知服务，关键读写使用用户归属条件；ArtifactService 加入文件访问边界。租户隔离是已实现的设计机制，仍应结合完整接口测试检查覆盖情况。默认高风险工具确认、取消与失败状态在前端以轨迹和卡片反馈。

4 主动服务闭环

定时任务、课程提醒及订阅服务将通知交给 DatabaseNotificationSink。服务保存 notification_outbox 后直接调用 NotificationStreamService.notify，向该用户在线连接推送；历史和未读记录通过查询接口读取。邮件是按用户设置启用的旁路渠道，并非仅在检测到离线时才发送。邮件异常被隔离处理，避免其失败直接中断站内通知逻辑。

5 当前边界与改进方向

外部模型与信息接口不可用时，整体体验仍会受限；SSE 连接可能断开，SQLite 形态也需要在扩展并发前评估。通知当前在事务方法内直接推送，尚不能等同于带独立派发器提交后投递与重试保障的可靠消息队列。后续可优先补充外部依赖监测、通知投递一致性和针对真实场景的端到端评测。

六 验证设计与演示安排

代码库包含 Skill 路由、工具确认、上下文预算、附件归属、会话记录、通知、课程解析和执行循环等测试。测试文件说明这些行为已有验证入口，但不能替代本次实际运行结果；报告不据此声称全部测试通过、上线稳定或取得特定成功率。

1 场景演示

演示一：登录知行，在对话中上传课程文件，观察解析、补充提问和课表查询结果。

演示二：提出包含天气与路线的出行问题，查看 Skill 和工具轨迹，并检查输出是否与接口结果一致。演示三：提出记忆保存请求，在记忆页面核对记录，随后通过新一轮对话检查是否合理召回。

演示四：请求修改或删除一个测试文件，确认界面先出现待确认状态，分别演示取消与允许。演示五：创建短周期测试提醒，在通知中心检查消息；启用邮件时检查旁路投递。演示六：上传图片或音频，核对视觉描述、转写与后续处理是否保持语义一致。以上为建议执行的演示步骤，不写作已经完成的用户试验。

2 建议评测指标

任务成功率应以业务状态变化和有效产物为标准；延迟记录从请求到首段可见正文及最终完成的时间；记忆评测分别检查保存、召回与无关内容误注入；确认机制检查未授权执行比例；租户隔离以两个测试账户交叉访问验证；通知区分数据库持久化、在线推送和邮件投递结果。

3 运行与交付

本地运行需要 Java 21、前端构建环境、SQLite 文件目录，以及所启用的模型、Embedding、Qdrant 和第三方接口配置。前端构建后由 Spring Boot 托管。演示数据宜使用不含真实身份信息的样例，模型密钥通过环境变量或本地配置管理，提交材料不附带真实密钥和个人数据。

知行的现阶段交付重点是可组合任务执行、多模态资料处理、可查看的个人记忆和持久化主动通知。后续迭代将以真实使用场景的完成质量为依据，逐步完善成本、延迟、稳定性和通知一致性，而不是仅扩充工具数量。